

Модели авторегрессии

Волхонский Денис
dvolkhonskiy@gmail.com

ВШЭ

2 февраля 2017 г.

1 Необходимая теория

1. Скользящее среднее (МА, Mean Average)

Имеем дискретные данные, хотим смоделировать какую-либо зависимость. Имеем:

- Оператор L : $Lx_{n+1} = x_n$ — оператор сдвига времени назад;
- Белый шум ε_n , $n \geq 0$, $E\varepsilon_n = 0$, $D\varepsilon_n = \sigma^2$, $E\varepsilon_n\varepsilon_m = 0 \forall n \neq m$;
- Многочлен $\beta(L) = b_0 + b_1L + \dots + b_qL^q$

Тогда скользящее среднее h_n порядка q называется $h_n = \mu + \beta(L) \cdot \varepsilon_n$. То есть мы имеем постоянное среднее плюс среднее значение последних q значений шума.

2. Авторегрессионная модель (AR)

$h_n = \mu_n + \sigma \cdot \varepsilon_n$, где $\mu_n = a_0 + a_1h_{n-1} + \dots + a_ph_{n-p}$.

Если задать $\alpha(L) = 1 - a_1L - \dots - a_pL^p$, тогда $\alpha(L)h_n = a_0 + \sigma\varepsilon_n$.

Условие стационарности AR:

- AR(1): $-1 < a_1 < 1$
- AR(2): $-1 < a_2 < 1$, $a_1 + a_2 < 1$, $a_2 - a_1 < 1$

3. Авторегрессионное скользящее среднее (ARMA, AutoRegression Mean Average)

ARMA(p, q) — смесь моделей AR и МА: $h_n = \mu_n + \sigma\varepsilon_n$, где

$$\mu_n = (a_0 + a_1h_{n-1} + \dots + a_ph_{n-p}) + (b_1\varepsilon_{n-1} + b_2\varepsilon_{n-2} + \dots + b_q\varepsilon_{n-q})$$

Согласно теореме Вольда, любой стационарный ряд может быть аппроксимирован моделью ARMA(p, q) (в том смысле, что если мы поставим вместо p и q бесконечность, то мы сможем точно описать любой стационарный ряд).

4. Интегральная модель (ARIMA)

ARIMA(p, d, q). Данная модель представляет собой случай, когда в модели ARMA вместо h_n подставляется ряд d-х разностей h'_n . $ARIMA(p, 0, q) = ARMA(p, q)$

5. Оценка коэффициентов в модели ARIMA(p, d, q)

- Как правило считают, что шум ε_n смоделирован гауссовским распределением. Тогда при заданных p, d, q параметры модели оцениваются методом максимального правдоподобия. То есть критерием качества является логарифм правдоподобия (Log Likelihood);
- d выбирается так, чтобы ряд был стационарным;
- p, q нельзя выбирать из ММП, т.к. LL растёт с ростом p и q;
- Используют авторреляционную функцию и частично автокорреляционную функцию

6. (Авторегрессионная модель условной неоднородности, Autoregressive Conditional Heteroskedastic model) ARCH

Пусть $\varepsilon_n \sim \mathcal{N}(0, 1)$. Тогда условно-гауссовская модель $h_n = \sigma_n \varepsilon_n$, где волатильность

$$\sigma^2 = \alpha_0 + \sum_{i=1}^p \alpha_i h_{n-i}^2, \quad \alpha_0 > 0, \quad \alpha_i \geq 0$$

7. Получение стационарности для ряда

- Преобразование Бокса-Кокса для нормализации дисперсии:

$$\hat{h}_n = \begin{cases} \ln h_n, & \lambda = 0 \\ \frac{h_n^\lambda - 1}{\lambda}, & \lambda \neq 0 \end{cases}$$

Параметр λ Выбирается так, чтобы минимизировать дисперсию или максимизировать правдоподобие модели

Что важно:

- Если значения ряда отрицательные, и преобразование невозможно, нужно прибавить к ряду константу;
 - Можно округлять значения λ , чтобы упростить интерпретацию;
 - Как правило преобразование слабо влияет на прогноз и сильно на предсказательный интервал
- Дифференцирование ряда (может применяться неоднократно):

$$\hat{h}_n = h_n - h_{n-1}$$

8. Выбор модели

- $AIC = 2L + 2(p + q + k + 1)$, где $k = 1$, если в ряде есть константа, $k = 0$, если константы нет;
- $BIC = -2L + (\log T - 2)(p + q + k + 1)$, где T — длина ряда;
- Автокорреляционная функция и частичная автокорреляционная функция;
- Метрика качества (например, MAE или MSE) на прошлых данных;